

Pengenalan Penyakit Pada Tanaman Pokok di Indonesia Dengan Metode *Convolutional Neural Network*

Handy Prayoga Angjaya, Kartika Gunadi, Rudy Adipranata
Program Studi Informatika, Fakultas Teknologi Industri Universitas Kristen Petra

Jl. Siwalankerto 121 – 131 Surabaya 60236

Telp. (031) – 2983000, Fax. (031) – 8436418

E-mail: hprayoga00@gmail.com, kgunadi@petra.ac.id, rudya@petra.ac.id

ABSTRAK

Di Indonesia makanan pokok yang paling banyak dikonsumsi adalah nasi, nasi tersebut berasal dari tanaman padi, selain nasi juga terdapat tanaman singkong dan jagung. Keberhasilan panen tanaman-tanaman tersebut dapat mempengaruhi kesejahteraan pangan negara, namun serangan hama dan penyakit menyebabkan kegagalan panen. Oleh karena itu, dibuatlah program yang dapat membantu dalam mengidentifikasi penyakit pada tanaman-tanaman tersebut sehingga dapat memaksimalkan hasil panen. Pada proses identifikasi penyakit, masalah yang sering terjadi adalah pengenalan karakteristik penyakit.

Dengan berkembangnya teknologi, pengenalan penyakit dapat dilakukan secara otomatis menggunakan *Neural Network*. Penelitian ini menggunakan metode *Convolutional Neural Network* (CNN) dengan arsitektur *Inception v3*. Juga, model yang digunakan akan dikonversikan menggunakan *TensorFlow Lite* sehingga bisa digunakan dalam aplikasi smartphone berbasis Android.

Hasil program dari penelitian ini mengidentifikasi penyakit pada tanaman jagung, kentang, singkong, dan padi. Berdasarkan pengujian yang dilakukan, didapatkan nilai akurasi rata-rata sebesar 90.77% pada pengujian data *testing*. Pengujian pada lapangan sesungguhnya menghasilkan rata-rata akurasi sebesar 65.00%.

Kata Kunci: tanaman pokok, *Convolutional Neural Network*, *Inception v3*, *TensorFlow Lite*

ABSTRACT

In Indonesia, the most consumed staple food is rice, the rice comes from the rice plants, besides rice, there is also cassava and corn plants. The success of harvesting these crops can affect the country's food welfare, but pest and diseases can cause crop failure. Therefore, a program was created to identify diseases in these plants to maximize crop yields. In the process of identifying the disease, the problem that often occurs is the identification of the characteristics of the disease.

With the development of technology, disease recognition can be done automatically using a Neural Network. This study uses the Convolutional Neural Network (CNN) method with the Inception v3 architecture. In addition, the model used will be converted using TensorFlow Lite so that it can be used on Android-based smartphone applications.

The program results from this study identified diseases in maize, potato, cassava, and rice plants. Based on the tests carried out, an average accuracy value of 90.77% was obtained in testing data test. Testing in the field actually produces an average accuracy of 65.00%.

Keywords: staple plant, *Convolutional Neural Network*, *Inception v3*, *TensorFlow Lite*

1. PENDAHULUAN

Makanan merupakan salah satu kebutuhan dasar manusia pada kehidupan sehari-hari. Di Indonesia makanan pokok yang paling banyak dikonsumsi adalah nasi, konsumsi beras di Indonesia merupakan yang tertinggi di dunia dan secara umum konsumsi jagung di Indonesia lebih tinggi dibandingkan negara lain [10]. Selain nasi, juga terdapat singkong atau ubi kayu. Singkong merupakan salah satu sumber karbohidrat lokal dari Indonesia yang menempati urutan ketiga setelah beras dan jagung sebagai bahan makanan pokok [3]. Selain ketiga makanan pokok tersebut, masih terdapat sumber makanan pokok lainnya yaitu kentang. Kentang merupakan tanaman pangan keempat terpenting di dunia setelah padi, gandum, dan jagung [15]. Keempat makanan pokok tersebut memainkan peranan penting dalam memenuhi kebutuhan karbohidrat manusia sebagai sumber energi untuk beraktivitas.

Keberhasilan panen dari tanaman-tanaman pokok tersebut dapat mempengaruhi industri pertanian suatu negara, tetapi gagal panen dapat terjadi kapan saja salah satu penyebabnya adalah penyakit dan serangan hama. Hampir 40% dari hasil panen dunia hilang karena penyakit dan serangan hama, menurut survei pada tahun 2012 [11]. Penyakit-penyakit dan serangan hama ini dapat dideteksi dengan melihat pada bagian-bagian tanaman. Bagian yang paling mudah untuk dideteksi adalah pada bagian daun karena tanda-tanda penyakit akan terlihat dengan jelas. Namun, tidak mudah untuk mengenali penyakit-penyakit tersebut dibutuhkan tenaga ahli dalam mengidentifikasi penyakit. Oleh karena itu, tenaga ahli tersebut dapat digantikan dengan sebuah program yang dapat mengenali jenis penyakit pada tanaman pokok.

Hingga saat ini, sudah banyak dilakukan riset mengenai pengenalan jenis penyakit pada daun tanaman. Salah satunya adalah pengenalan penyakit pada daun pisang yang dilakukan oleh [2]. Penelitian ini melakukan pengenalan menggunakan *Convolutional Neural Network* (CNN) dengan arsitektur LeNet sekaligus melakukan uji coba apakah informasi warna berpengaruh pada akurasi pengenalan penyakit, hasil yang didapatkan cukup baik dan membuktikan informasi warna memberikan akurasi yang lebih tinggi daripada *grayscale*. Penelitian untuk mengenali penyakit pada daun juga dilakukan oleh [4]. Pada penelitian ini melakukan pendekatan yang berbeda yaitu gambar dari 5 jenis penyakit pada daun tanaman dikumpulkan dan gambar RGB diubah menjadi *Lab color space*, lalu gambar disegmentasi dan diubah menjadi gambar biner. Kemudian dilakukan *feature extraction* dan metode *K-nearest neighbor* digunakan untuk mengklasifikasikan.

Metode yang diajukan di proposal ini terdiri dari 2 tahap. Tahap pertama adalah pembuatan model menggunakan Convolutional Neural Network dengan arsitektur Inception v3 untuk pengenalan penyakit, dimana CNN model ini mempunyai struktur yang lebih dalam sehingga waktu training yang dibutuhkan lebih sedikit dan mempunyai ukuran input size yang lebih fleksibel, tetapi masih mempunyai tingkat akurasi yang setara dengan model-model lainnya [13]. Tahap kedua adalah pembuatan aplikasi smartphone berbasis android dan penerapan model neural network pada aplikasi.

2. LANDASAN TEORI

2.1 Tanaman Pokok

Makanan pokok adalah makanan yang menjadi makanan utama [5], makanan pokok yang paling banyak dikonsumsi di Indonesia adalah nasi dan jagung [10]. Makanan-makanan tersebut diperoleh dari berbagai sumber salah satunya melalui tanaman yaitu tanaman pokok, tanaman-tanaman pokok di seluruh dunia berbeda-beda bergantung pada iklim dan jenis tanah yang dimilikinya.

2.2 Penyakit dan Hama pada Tanaman

Penyakit adalah sesuatu yang menyebabkan terjadinya gangguan pada makhluk hidup atau gangguan kesehatan yang disebabkan oleh bakteri, virus, atau kelainan sistem faal atau jaringan organ tubuh [6], penyakit-penyakit pada tanaman umumnya terjadi disebabkan oleh beberapa faktor yaitu jamur (fungus), bakteri, dan virus. Hama adalah hewan yang mengganggu produksi pertanian seperti babi hutan, tupai, tikus, dan terutama serangga [7].

2.3 TensorFlow

TensorFlow adalah sebuah *open-source framework* yang digunakan untuk membantu dalam *machine learning*, TensorFlow dapat digunakan untuk banyak hal tetapi memiliki fokus khusus pada proses *training* dan inferensi pada *deep neural network* [8]. TensorFlow Lite adalah sekumpulan *tools* yang disediakan oleh TensorFlow untuk membantu *developer* menjalankan model TensorFlow pada perangkat *mobile*, *embedded*, dan IoT (*Internet of Things*). TensorFlow Lite memungkinkan inferensi *machine learning* di perangkat dengan *latency* rendah dan memiliki ukuran biner yang kecil [9].

2.4 Keras

Keras adalah sebuah *library open-source* yang menyediakan *interface* untuk *artificial neural network*, *library* ini dirancang sebagai *deep learning API* yang ditulis dalam bahasa pemrograman Python [12].

2.5 Convolutional Neural Network

Convolutional Neural Network (CNN) pertama kali diusulkan oleh Hubel dan Wiesel pada tahun 1960-an, mereka mengamati untuk pertama kalinya bahwa neuron pada korteks visual sensitif terhadap tepi yang bergerak sehingga mengusulkan konsep “*receptive field*”. Lalu pada awal tahun 1980-an LeCun et al. memperkenalkan CNN dengan nama “LeNet-5” [14]. Konsep utama dari CNN adalah meniru pola konektivitas neuron di otak manusia, pola-pola yang ditiru terdiri menjadi beberapa elemen yaitu *convolutional layer*, *non-linearity layer*, *pooling layer*, dan *fully connected layer* [1].

2.6 Inception V3

Inception adalah sebuah arsitektur dari *deep convolutional neural network*, yang bertanggung jawab untuk menetapkan *state of the art* untuk klasifikasi dan deteksi di *ImageNet Large-Scale Visual*

Recognition Challenge 2014 (ILSVRC14) [13]. *Inception v3* adalah salah satu arsitektur yang dihasilkan, *Inception v3* merupakan pengembangan dari *Inception* sebelumnya, ide yang dikembangkan adalah faktorisasi untuk mengurangi *overfitting* dengan sebuah modul *grid size reduction* yang efisien.

2.7 Confusion Matrix

Confusion matrix adalah matriks atau tabel yang digunakan sebagai pengukuran performa dari sebuah model klasifikasi. Terdapat 2 jenis *confusion matrix* yaitu *2-class confusion matrix* dan *multi-class confusion matrix*. Pengukuran performa dilakukan dengan perhitungan dari isi tabel *confusion matrix* yaitu *accuracy*, *precision*, *recall*, dan *f1-score*.

3. ANALISA DAN DESAIN SISTEM

3.1 Analisis Data

Data yang digunakan dalam penelitian ini adalah gambar daun tanaman berwarna RGB (*Red*, *Green*, *Blue*) dengan format ekstensi JPG (*Joint Photographic Group*).

3.1.1 Pengumpulan data

Dataset daun tanaman yang dikumpulkan didapatkan melalui 3 sumber yaitu sebanyak 9148 gambar tanaman jagung dan 7135 gambar tanaman kentang dari *Plant Village*, sebanyak 9430 gambar tanaman singkong dari *iCassava 2019*, dan sebanyak 3355 gambar tanaman padi dari *University of California*.

3.1.2 Pembagian data

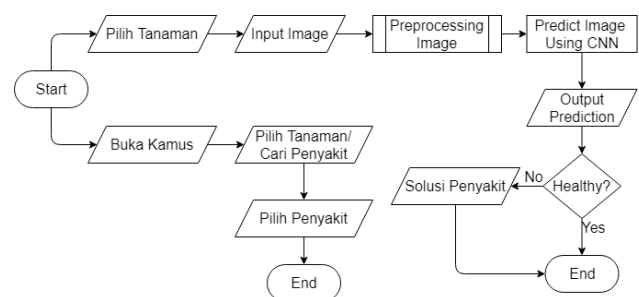
Dataset yang diperoleh terbagi menjadi 2 bagian. Yang pertama, sebagian besar data digunakan untuk training, dan yang kedua sebagian data digunakan untuk testing. Proporsi data yang digunakan untuk training adalah sebesar 80%, dan dataset kedua yang digunakan untuk testing sebanyak 20% dari jumlah dataset.

3.1.3 Pengolahan data

Dataset yang dikumpulkan berasal dari sumber yang berbeda-beda sehingga mempunyai resolusi gambar yang bervariasi, gambar dengan resolusi yang berbeda perlu dilakukan pengolahan menjadi ukuran lebar dan tinggi yang *fixed*. Selain resolusi gambar, dataset juga diberikan augmentasi untuk menambahkan jumlah dataset yang terbatas sekaligus mengurangi kemungkinan *overfitting* pada model yang merupakan salah satu kelemahan dari CNN. Dalam penelitian ini percobaan jenis augmentasi yang akan dilakukan yaitu *flipping*, *color space*, *rotation*, dan *translation*.

3.2 Analisis Sistem

Analisis sistem membahas permasalahan bagaimana data akan diproses, sistem akan mengolah gambar yang diinput dan diproses sehingga menghasilkan *output* untuk memprediksi penyakit pada tanaman. Arsitektur sistem dapat dilihat dalam *flowchart* pada Gambar 1.



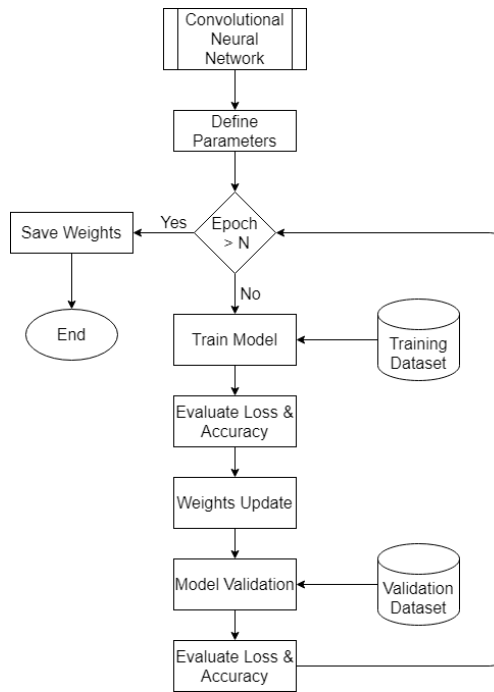
Gambar 1. Arsitektur sistem

3.2.1 Convolutional neural network

Pada metode *convolutional neural network* ini terbagi dalam 2 tahap yaitu *training* dan *testing*.

3.2.1.1 Training

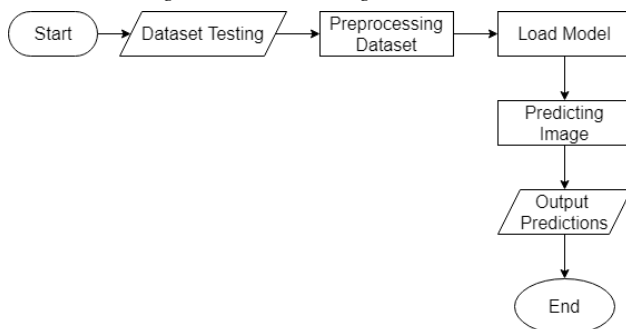
Pada Gambar 2 proses *training* diawali dengan menentukan parameter *epoch*, *optimizer*, *learning rate*, *loss function*, dan *evaluation metrics*. Setiap 1 *epoch* selesai *evaluation metrics* akan menunjukkan *loss* dan tingkat akurasi dari model sekaligus memperbaharui *weight* dari model, setelah *weight* di-update model akan divalidasi menggunakan dataset *validation* lalu dilakukan evaluasi untuk *loss* dan akurasi.



Gambar 2. Alur *training* model CNN

3.2.1.2 Testing

Tahap *testing* model CNN dilakukan menggunakan dataset *testing* yang telah dipisahkan ke dalam folder-folder berdasarkan penyakitnya. Pada Gambar 3 diawali dengan menyiapkan model yang telah di-*train*, lalu gambar akan dilakukan *preprocessing* sebelum diprediksi. Setelah itu, model akan memprediksi penyakit berdasarkan *weight* dari hasil *training*.



Gambar 3. Alur *testing* model CNN

4. PENGUJIAN SISTEM

Pada bab ini akan dijelaskan mengenai pengujian sistem dan aplikasi yang telah dibuat, pengujian dilakukan menggunakan sebagian dari dataset yaitu 20% dari keseluruhan dataset dan pengujian juga dilakukan secara langsung pada tanaman yang terinfeksi dari dinas pertanian.

4.1 Pengujian Sistem Neural Network

Pengujian sistem *neural network* dilakukan dengan mengubah parameter yang mungkin berpengaruh pada model, proses *training* dilakukan menggunakan model *Inception v3*. Percobaan ini dilakukan untuk menemukan konfigurasi terbaik untuk model CNN dengan performa terbaik.

4.1.1 Pengujian preprocessing pada data

Keras telah menyediakan sebuah *preprocessing* gambar untuk membantu model *Inception v3* mengenali gambar dengan lebih baik, pengujian ini dilakukan untuk membandingkan apakah *preprocessing* tersebut memberikan hasil yang lebih baik atau sebaliknya. Percobaan ini dilakukan pada dataset tanaman kentang dan singkong, parameter-parameter yang digunakan adalah arsitektur *Inception v3* sebagai struktur model CNN, jumlah *epoch* sebanyak 10, dan tanpa augmentasi data. Hasil percobaan *preprocessing* dapat dilihat pada Tabel 1.

Tabel 1. Hasil pengujian *preprocessing* dari Keras

Tanaman	Akurasi terendah	Akurasi tertinggi	Rata-rata akurasi	Rata-rata loss function
Kentang (original)	88.90%	100.00%	98.72%	0.0425
Kentang (preprocessing)	99.03%	100.00%	99.87%	0.0033
Singkong (original)	75.76%	87.05%	82.75%	0.6291
Singkong (preprocessing)	56.06%	90.38%	84.91%	0.5859

4.1.2 Pengujian augmentasi pada data

Pada pengujian ini dataset untuk *training* diberikan augmentasi, percobaan ini dilakukan untuk menguji apakah model dapat mengenali penyakit dengan lebih baik jika diberikan augmentasi atau sebaliknya. Pengujian ini dilakukan pada dataset tanaman singkong, parameter-parameter yang digunakan adalah arsitektur *Inception v3* sebagai struktur model CNN, jumlah *epoch* sebanyak 10, dan tanpa *preprocessing* gambar. Hasil percobaan kombinasi jenis augmentasi terbaik dapat dilihat pada Tabel 2.

Tabel 2. Hasil pengujian augmentasi data

Augmentasi	Akurasi terendah	Akurasi tertinggi	Rata-rata akurasi	Rata-rata loss function
Original	69.57%	84.00%	74.76%	0.7928
Rotation + Translastion (vertical) + Flipping + Zoom	72.16%	89.07%	85.59%	0.5564

4.1.3 Pengujian target resize gambar

Pada percobaan ini gambar akan di-*resize* menjadi ukuran tertentu untuk mengetahui pengaruh resolusi gambar pada performa model, pengujian ini dilakukan pada dataset tanaman kentang dan singkong. Dataset tanaman kentang pada setiap gambarnya memiliki resolusi yang sama dengan tinggi 256 dan lebar 256 piksel (256 x 256), sedangkan pada dataset tanaman singkong mempunyai dataset gambar dengan resolusi yang berbeda-beda dengan kisaran resolusi tinggi antara 500-800 dan lebar 500-800 piksel. Pengujian ini akan mengubah resolusi gambar menjadi 3 tahap, tahap pertama resolusi gambar sedekat mungkin dengan resolusi gambar asli, tahap kedua resolusi gambar setengah dari resolusi asli, dan tahap ketiga dengan resolusi 2 kali dari gambar asli. Pengujian ini dilakukan menggunakan arsitektur Inception v3 dengan parameter *epoch* sebanyak 10, tanpa preprocessing, dan tanpa augmentasi. Hasil percobaan ini dapat dilihat pada Tabel 3.

Tabel 3. Hasil pengujian resolusi pada gambar

Tanaman	Akurasi terendah	Akurasi tertinggi	Rata-rata akurasi	Rata-rata loss function
Kentang (128x128)	89.04%	99.51%	97.41%	0.1260
Kentang (original 256x256)	88.90%	100.00%	98.72%	0.0425
Kentang (512x512)	91.63%	100.00%	98.72%	0.0466
Singkong (256x256)	66.70%	82.24%	78.37%	0.8135
Singkong (original 512x512)	75.76%	87.05%	82.75%	0.6291
Singkong (1024x1024)	70.40%	88.25%	79.75%	0.6997

4.1.4 Pengujian learning rate

Pada percobaan ini parameter *learning rate* akan dilakukan percobaan untuk menemukan nilai terbaik untuk *training* model, pengujian ini dilakukan dengan *learning rate* sebesar 0.05, 0.03, 0.01, 0.005, 0.003, 0.001, 0.0005, 0.0003, dan 0.0001 pada dataset tanaman singkong dengan parameter *epoch* sebanyak 10, tanpa preprocessing, dan tanpa augmentasi. Hasil dari percobaan ini dapat dilihat pada Tabel 4.


Tabel 4. Hasil pengujian learning rate

Learning rate	Akurasi terendah	Akurasi tertinggi	Rata-rata akurasi	Rata-rata loss function
0.05	5.64%	64.11%	42.46%	2.5522
0.03	8.79%	60.87%	37.86%	2.5544
0.01	20.07%	78.26%	52.29%	2.8315
0.005	19.24%	76.23%	57.97%	1.7366
0.003	12.49%	71.32%	50.30%	2.1689
0.001	39.04%	82.15%	62.02%	1.8694
0.0005	54.67%	84.55%	66.80%	1.1755

0.0003	60.87%	84.55%	73.58%	0.9016
0.0001	54.67%	84.55%	66.80%	1.1755

4.1.5 Pengujian jumlah epoch

Pada percobaan ini parameter *epoch* akan dilakukan uji coba untuk menemukan jumlah *epoch* yang memberikan performa terbaik. Percobaan ini dilakukan pada dataset tanaman singkong dengan parameter *learning rate* 0.0003, tanpa preprocessing, dan tanpa augmentasi data. Hasil percobaan *epoch* dapat dilihat pada Gambar 4.



Gambar 4. Hasil pengujian jumlah epoch


Dari hasil percobaan tersebut menunjukkan nilai akurasi testing tertinggi didapatkan pada *epoch* ke 22 yaitu 90.56% dengan nilai *loss function* sebesar 0.5524, dari keseluruhan *epoch* secara rata-rata akurasi yang didapatkan adalah 85.46%. Hasil percobaan ini menunjukkan performa terbaik bisa didapatkan dengan jumlah sebanyak 30 *epochs*.

4.2 Pembuatan Model

Setelah melakukan pengujian pada sistem *neural network* parameter-parameter yang memberikan performa terbaik untuk model telah didapatkan, dari parameter tersebut model dari setiap tanaman akan dibuat dan dikonversi menjadi ekstensi Tensorflow Lite (.tflite).

4.2.1 Model tanaman jagung

Pembuatan model tanaman jagung dibuat menggunakan dataset yang diberikan diaugmentasi dan preprocessing gambar dari Keras. Parameter-parameter untuk pelatihan model adalah *epoch* sebanyak 30, *batch size* sebanyak 32, menggunakan *optimizer* Adam, *learning rate* sebesar 0.0003, *categorical cross entropy* sebagai *loss function*, dan metrik penilaian menggunakan akurasi. Hasil dari *training* model jagung dapat dilihat pada Gambar 5.




Gambar 5. Grafik akurasi training model tanaman jagung

Pada percobaan tersebut menunjukkan hasil pelatihan model menghasilkan rata-rata akurasi *testing* sebesar 97.92% dengan hasil terbaik didapatkan pada *epoch* ke 16 dengan tingkat akurasi 99.45%, model tersebut menghasilkan nilai *precision* sebesar 99.02%, *recall* sebesar 98.78%, dan *F1-score* sebesar 98.90%.

4.2.2 Model tanaman kentang

Pembuatan model tanaman kentang dibuat menggunakan *input layer* dengan resolusi tinggi sebesar 256 piksel, resolusi lebar sebesar 256 piksel, dan 3 *channel* warna (*red, green, & blue*). Dataset tanaman kentang diberikan diaugmentasi dan *preprocessing* gambar dari Keras. Parameter-parameter yang digunakan untuk melatih model adalah *epoch* sebanyak 30, *batch size* sebesar 32, menggunakan *optimizer* Adam, *learning rate* 0.0003, *categorical cross entropy* sebagai *loss function*, dan metrik penilaian menggunakan akurasi. Hasil dari *training* model kentang dapat dilihat pada Gambar 6.




Gambar 6. Grafik akurasi *training* model tanaman kentang

Pada percobaan tersebut menunjukkan hasil pelatihan model menghasilkan rata-rata akurasi *testing* sebesar 97.10% dengan hasil terbaik didapatkan pada *epoch* ke 20, 21, 22, dan 23 dengan tingkat akurasi 100.00%, model tersebut menghasilkan nilai *precision*, *recall*, dan *F1-score* sebesar 100.00%.

4.2.3 Model tanaman padi

Pembuatan model pada tanaman padi dibuat menggunakan *input layer* dengan resolusi tinggi sebesar 1880 piksel, resolusi lebar 1880 piksel, dan 3 *channel* warna (*red, green, & blue*). Dataset dari tanaman padi diberikan diaugmentasi dan *preprocessing* gambar dari Keras. Parameter-parameter yang digunakan untuk melatih model adalah *epoch* sebanyak 30, *batch size* sebesar 2, menggunakan *optimizer* Adam, *learning rate* 0.0003, *categorical cross entropy* sebagai *loss function*, dan metrik penilaian menggunakan akurasi. Hasil dari *training* model kentang dapat dilihat pada Gambar 7.




Gambar 7. Grafik akurasi *training* model tanaman padi

Pada percobaan tersebut menampilkan hasil pelatihan model mempunyai tingkat akurasi *training* dan *testing* yang cukup berbeda, pelatihan ini menghasilkan rata-rata akurasi *training* sebesar 88.35% dan *testing* sebesar 67.04%. Akurasi *testing* model yang tertinggi didapatkan pada *epoch* ke-29 yaitu sebesar 73.47% dengan nilai *precision* sebesar 71.19%, *recall* sebesar 66.97%, dan *F1-score* sebesar 68.27%.

4.2.4 Model tanaman singkong

Pembuatan model pada tanaman singkong dibuat menggunakan *input layer* dengan resolusi tinggi sebesar 512 piksel, resolusi lebar sebesar 512 piksel, dan 3 *channel* warna (*red, green, & blue*). Dataset dari tanaman kentang diberikan diaugmentasi dan *preprocessing* gambar dari Keras. Parameter-parameter yang digunakan untuk melatih model adalah *epoch* sebanyak 30, *batch size* sebesar 16, menggunakan *optimizer* Adam, *learning rate* 0.0003, *categorical cross entropy* sebagai *loss function*, dan metrik penilaian menggunakan akurasi. Hasil dari *training* model singkong dapat dilihat pada Gambar 8.



Gambar 8. Grafik akurasi *training* model tanaman singkong

Pada percobaan ini menunjukkan hasil pelatihan model terjadi peningkatan dan penurunan tingkat akurasi yang signifikan selama proses *training*, pada *epoch* kelima terjadi penurunan lalu pada *epoch* keenam terjadi peningkatan dan pada *epoch* ke-sebelas dan dua belas terjadi penurunan lalu pada *epoch* ke-tiga belas terjadi peningkatan kembali. Pelatihan model ini menghasilkan rata-rata akurasi *testing* sebesar 83.34% dengan hasil terbaik didapatkan pada *epoch* ke-20 dengan tingkat akurasi 90.19%, model tersebut menghasilkan nilai *precision* sebesar 87.18%, *recall* sebesar 87.83%, dan *F1-score* sebesar 87.25%.

4.3 Pengujian Model pada Tanaman Terinfeksi

Model-model yang telah di-*training* akan dilakukan pengujian terhadap gambar langsung dari tanaman yang terinfeksi, pengujian ini dilakukan untuk mengetahui seberapa baik performa model pada kondisi tanaman yang sesungguhnya. Pengambilan gambar dilakukan menggunakan *smartphone* Samsung S8 dengan resolusi pengambilan gambar 2160 x 2160, gambar diambil sebanyak 4 kali untuk setiap tanaman. Keempat gambar tersebut diambil dari jarak yang berbeda yaitu 30 cm, 50 cm, 70 cm, dan 70 cm dirotasikan 90 derajat, contoh gambar dapat dilihat pada Gambar 9. Pengujian ini dilakukan pada tanaman jagung, singkong, dan padi.

Pada pengujian tanaman jagung dilakukan pada 2 jenis penyakit yaitu *common rust*, *gray leaf spot*, dan sehat. Dalam uji coba ini diambil 20 gambar dari 3 kategori tersebut, pada proses pengambilan data tidak ditemukan tanaman jagung yang terinfeksi penyakit *leaf blight*.



Gambar 9. Contoh pengambilan gambar tanaman terinfeksi

Pengujian ini menunjukkan model mempunyai tingkat akurasi sebesar 85.00%, *precision* sebesar 88.57%, *recall* sebesar 83.33%, dan *F1-score* sebesar 84.86%.

Pada pengujian tanaman padi dilakukan pada 2 jenis penyakit yaitu *brown spot*, *leaf blast*, dan sehat. Dalam uji coba ini diambil 20 gambar dari 3 kategori tersebut, pada proses pengambilan data tidak ditemukan tanaman padi yang terinfeksi penyakit *hispa*. Pengujian ini menunjukkan model mempunyai tingkat akurasi sebesar 50.00% dengan *precision* sebesar 52.50%, *recall* sebesar 40.62%, dan *F1-score* sebesar 37.22%. Kesalahan prediksi terjadi pada pengujian tanaman yang sehat dikarenakan *background* gambar yang tercampur dengan daun padi lainnya.

Pada pengujian tanaman singkong dilakukan pada 3 jenis penyakit yaitu *bacterial blight*, *brown streak*, *green mite*, *mosaic disease*, dan sehat. Dalam uji coba ini diambil 20 gambar dari 4 kategori tersebut, pada proses pengambilan data tidak ditemukan tanaman singkong yang terinfeksi penyakit *green mite*. Pengujian ini menunjukkan model mempunyai tingkat akurasi sebesar 60.00%, *precision* sebesar 54.54%, *recall* sebesar 40.00%, dan *F1-score* sebesar 43.50%. Kesalahan klasifikasi terjadi pada pengujian tanaman sehat dikarenakan model kesulitan untuk membedakan antara penyakit *green mite* dengan tanaman yang sehat dikarenakan karakteristiknya yang mirip.

4.4 Pengujian Aplikasi

Pengujian ini dilakukan untuk membandingkan apakah terjadi perubahan performa pada model ketika dikonversi dibandingkan dengan format ekstensi .h5. Pengujian dibagi menjadi 2 tahap, tahap pertama yaitu menghitung seberapa lama model memprediksi gambar menggunakan satu gambar dari setiap kategori penyakit dan sehat tanaman, tahap yang kedua yaitu pengujian kemampuan prediksi model dilakukan menggunakan 10 gambar acak dari dataset *testing* masing-masing jenis penyakit dan keadaan sehat tanaman, juga pengujian dilakukan menggunakan gambar tanaman terinfeksi yang diambil langsung.

Pengujian pada Tabel 5 dilakukan menggunakan laptop ASUS A442U berspesifikasi intel core i5-8250U dengan RAM 8GB dan *smartphone* Samsung S8 dengan RAM 4GB, hasil yang didapatkan menunjukkan performa waktu model secara rata-rata stabil dan hasil prediksi menggunakan laptop mempunyai waktu yang lebih singkat dibandingkan *smartphone*. Namun, terjadi kenaikan waktu prediksi pada model tanaman singkong .tflite di *smartphone* dikarenakan ukuran *input layer* yang lebih besar

daripada tanaman jagung dan kentang. Sedangkan pada model tanaman padi .tflite di *smartphone*, model tidak bisa melakukan prediksi dikarenakan keterbatasan *resource* (RAM) dari *smartphone*.

Tabel 5. Pengujian performa waktu model memprediksi

Tanaman (rata-rata)	Model .h5 - Laptop (ms)	Model .tflite - Laptop (ms)	Model .tflite - Smartphone (ms)
Jagung	110,25	119	754,25
Kentang	102,33	167,33	773,33
Padi	3309	5275,75	-
Singkong	285,8	349	2352,8

Pengujian dilakukan pada dataset *testing* yang menunjukkan secara keseluruhan model .h5 dan model .tflite mempunyai performa yang hampir setara, tetapi pada model tanaman singkong model .tflite di *smartphone* mengalami sedikit penurunan performa pada saat memprediksi penyakit *bacterial blight*.

Pada pengujian tanaman jagung model .tflite di *smartphone* menghasilkan akurasi yang sama dengan model .h5 yaitu sebesar 85.00%, disertai dengan *precision* sebesar 88.42%, *recall* sebesar 83.33%, dan *F1-score* sebesar 85.18%. Sedangkan pada pengujian tanaman singkong model .tflite mempunyai akurasi yang lebih rendah dibandingkan model .h5 yaitu sebesar 50.00% dengan *precision* sebesar 37.33, *recall* sebesar 32.50%, dan *F1-score* sebesar 33.65%.

4.5 Pengujian Background Gambar

Pada pengujian ini dilakukan pengambilan gambar tanaman yang sama, namun mempunyai *background* yang berbeda. Percobaan ini menggunakan model .h5 pada tanaman padi, percobaan ini bertujuan untuk mengetahui apakah *background* dapat berdampak dalam performa model. Percobaan ini dapat dilihat pada Gambar 10.



Gambar 10. Pengujian *background* pada pengambilan gambar tanaman

Pengujian ini menunjukkan pengambilan gambar *background* yang tidak tumpang tindih dengan tanaman di belakangnya mempunyai performa yang lebih baik.

5. KESIMPULAN DAN SARAN

Pada bab ini akan dijelaskan kesimpulan yang diperoleh dalam penelitian penggunaan *Convolutional Neural Network* untuk mendeteksi penyakit pada tanaman pokok. Pada bab ini juga disertakan sejumlah saran untuk pengembangan skripsi lebih lanjut.

5.1 Kesimpulan

Dari hasil perancangan dan pembuatan sistem dan aplikasi dapat diambil kesimpulan antara lain:

- Penggunaan metode Convolutional Neural Network dengan arsitektur Inception v3 dalam pengenalan penyakit pada tanaman mendapatkan rata-rata akurasi sebesar 90.77% pada dataset testing dan mendapatkan rata-rata akurasi sebesar 65.00% pada pengujian langsung tanaman jagung, padi, dan singkong.
- Berdasarkan pengujian pada poin ke-4, preprocessing dari Keras dan augmentasi data berhasil meningkatkan performa model. Parameter terbaik yang didapatkan yaitu resolusi gambar original adalah resolusi yang terbaik, learning rate terbaik adalah 0.0003, dan jumlah epoch terbaik sebanyak 30.
- Konversi model .h5 menjadi .tflite memberikan hasil yang cukup memuaskan karena dapat mengurangi jumlah ukuran model dari 251 mb menjadi 83 mb, namun tetap mempunyai performa yang hampir setara dengan model .h5.
- Pada model tanaman padi mempunyai ukuran input layer yang cukup besar sehingga tidak dapat diproses menggunakan smartphone karena keterbatasan resource.
- Untuk meningkatkan hasil prediksi model, objek harus terlihat jelas dan tidak terganggu dengan background tanaman lainnya. Segmentasi yang sesuai untuk gambar juga diperlukan untuk meningkatkan hasil prediksi pada neural network.

5.2 Saran

Saran yang dapat diberikan untuk menyempurnakan dan mengembangkan skripsi ini lebih lanjut antara lain:

- Menambahkan dataset yang lebih banyak dan bervariasi untuk meningkatkan performa model neural network.
- Mengembangkan segmentasi untuk menghilangkan background objek untuk mendapatkan hasil yang lebih baik.
- Menggunakan struktur model lainnya agar mendapatkan model yang lebih akurat dan menggunakan resource yang lebih sedikit.
- Menyesuaikan teknologi yang digunakan dengan pengujian agar bisa mendapatkan hasil yang maksimal.

6. DAFTAR REFERENSI

- [1] Albawi, S. et al. 2018. Understanding of a convolutional neural network. *Proceedings of 2017 International Conference on Engineering and Technology, ICET 2017* (2018).
- [2] Amara, J. et al. 2017. A deep learning-based approach for banana leaf diseases classification. *Lecture Notes in Informatics (LNI), Proceedings - Series of the Gesellschaft für Informatik (GI)* (2017).
- [3] Gunawan, S. et al. 2017. The Utilization of Cassava and Sorghum Flours as A Staple Food in Indonesia. *IPTEK Journal of Proceedings Series*. (2017). DOI:<https://doi.org/10.12962/j23546026.y2018i1.3365>.
- [4] Hossain, E. et al. 2019. A Color and Texture Based Approach for the Detection and Classification of Plant Leaf Disease Using KNN Classifier. *2nd International Conference on Electrical, Computer and Communication Engineering, ECCE 2019* (2019).
- [5] <https://kbbi.kemdikbud.go.id/entri/makanan%20pokok>. Accessed: 2021-06-10.
- [6] <https://kbbi.kemdikbud.go.id/entri/penyakit>. Accessed: 2021-06-10.
- [7] <https://kbbi.kemdikbud.go.id/entri/hama>. Accessed: 2021-06-10.
- [8] <https://www.tensorflow.org/>. Accessed: 2021-06-10.
- [9] <https://www.tensorflow.org/lite>. Accessed: 2021-06-10.
- [10] Jati, K. 2014. Staple Food Balance Sheet, Coefficient of Variation, and Price Disparity in Indonesia. *Journal of Advanced Management Science*. (2014). DOI:<https://doi.org/10.12720/joams.2.1.65-71>.
- [11] Santhosh Kumar, S. and Raghavendra, B.K. 2019. Diseases Detection of Various Plant Leaf Using Image Processing Techniques: A Review. *2019 5th International Conference on Advanced Computing and Communication Systems, ICACCS 2019* (2019).
- [12] Simple. Flexible. Powerful.: <https://keras.io/>. Accessed: 2021-06-10.
- [13] Szegedy, C. et al. 2015. Going deeper with convolutions. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition* (2015).
- [14] Wang, W. and Yang, Y. 2019. Development of convolutional neural network and its application in image classification: a survey. *Optical Engineering*. (2019). DOI:<https://doi.org/10.1117/1.oe.58.4.040901>.
- [15] Zhang, H. et al. 2017. Progress of potato staple food research and industry development in China. *Journal of Integrative Agriculture*.